

Γλώσσες Προγραμματισμού Μεταγλωττιστές

Συντακτική Ανάλυση

Πανεπιστήμιο Μακεδονίας
Τμήμα Εφαρμοσμένης Πληροφορικής

Ηλίας Σακελλαρίου

Δομή

- Συντακτική Ανάλυση
- Γραμματικές χωρίς συμφραζόμενα.
 - Αυτόματα Στοίβας
- Οι συναρτήσεις FIRST και FOLLOW.
- Συντακτικοί Αναλυτές από πάνω προς τα κάτω (top-down)

Φάσεις Μεταγλώττισης

Αρχικό Πρόγραμμα

Λεκτική Ανάλυση

λεκτικές μονάδες

Συντακτική Ανάλυση

συντακτικό δένδρο

Σημασιολογική Ανάλυση

συντακτικό δένδρο

Παραγωγή Ενδιάμεσου Κώδικα

ενδιάμεσος κώδικας

Βελτιστοποίηση Ενδιάμεσου Κώδικα

ενδιάμεσος κώδικας

Παραγωγή Τελικού Κώδικα

τελικός κώδικας

Βελτιστοποίηση Τελικού Κώδικα

Τελικό Πρόγραμμα

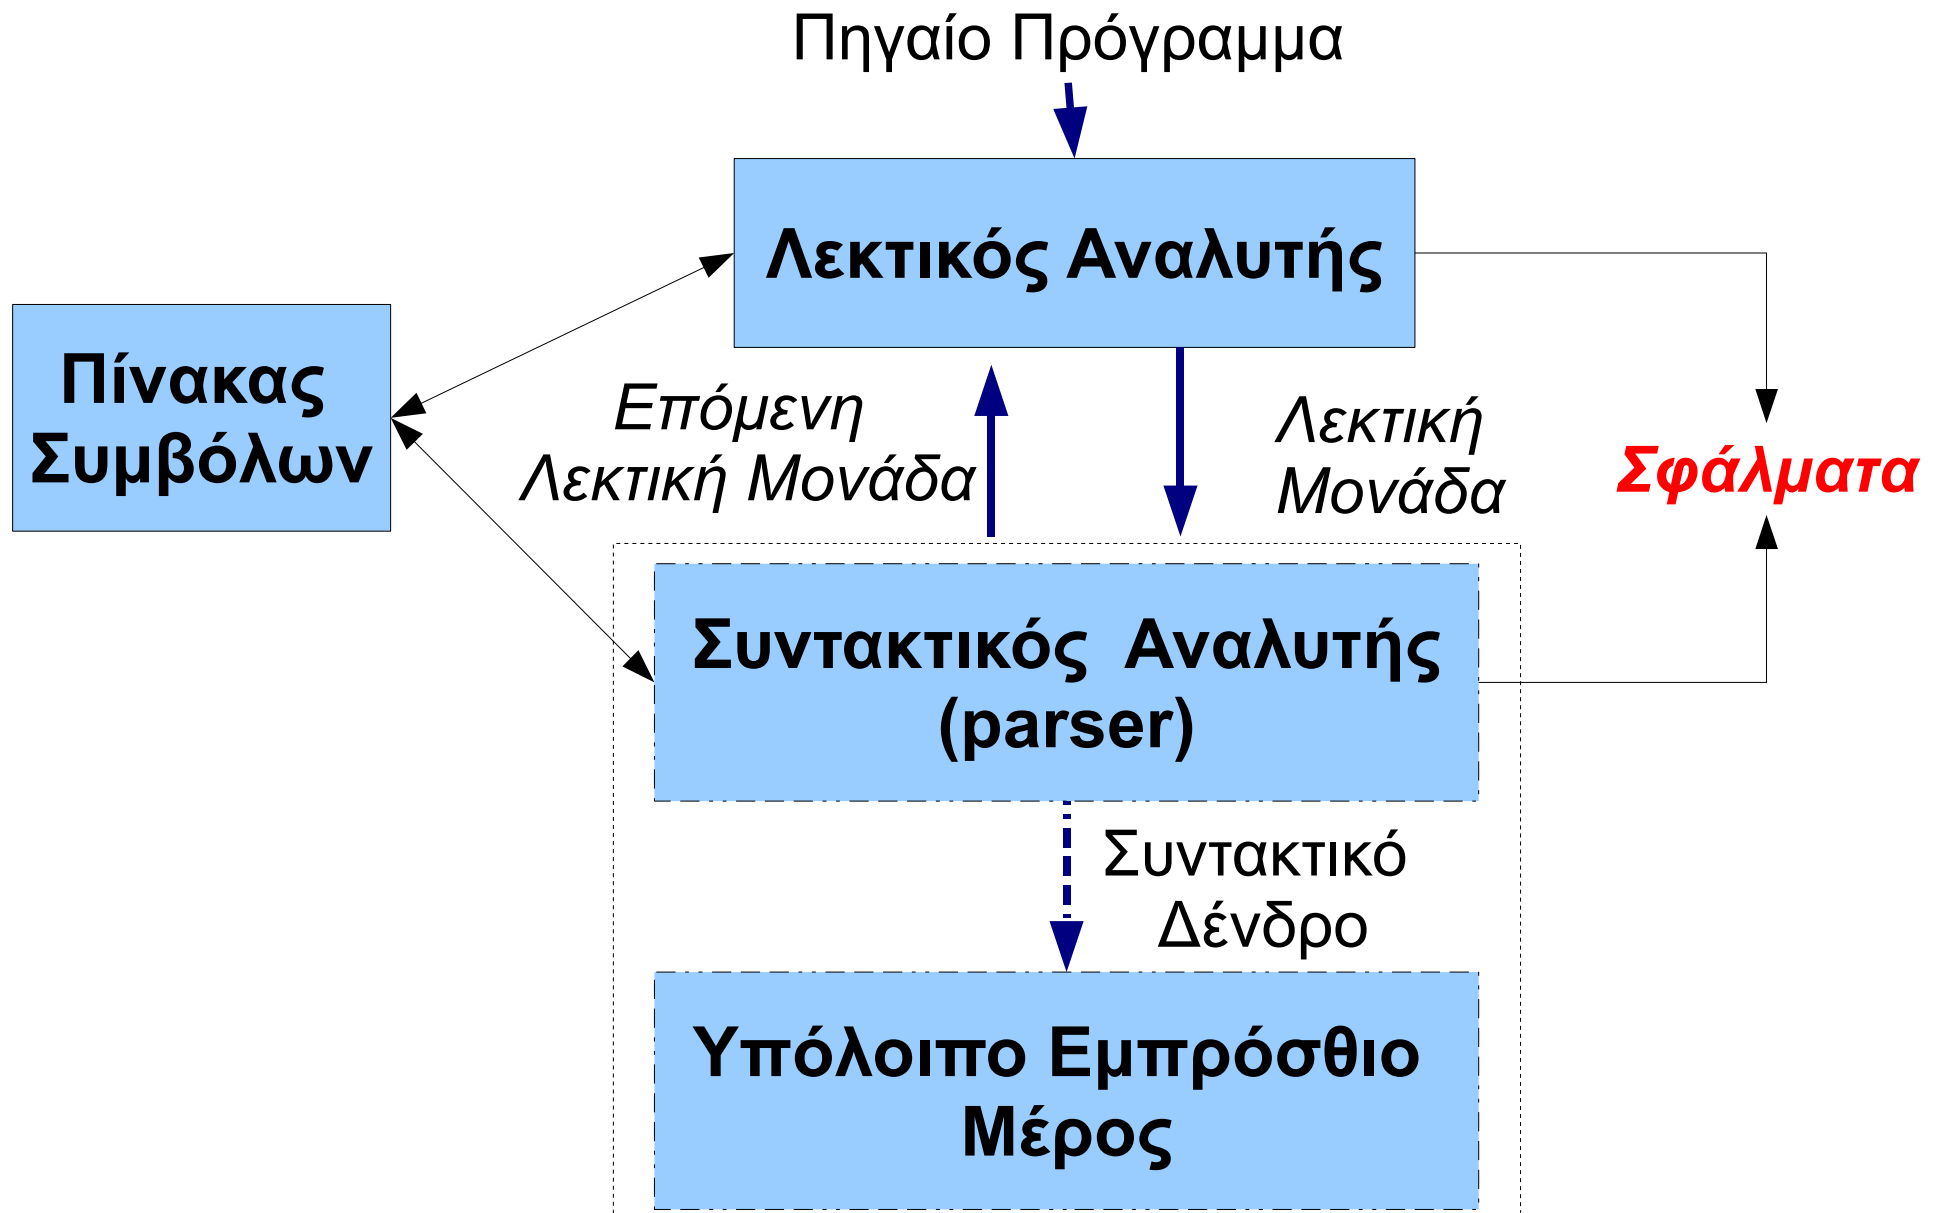
Χειριστής
Σφαλμάτων

Πίνακας
Συμβόλων

Συντακτική Ανάλυση (Syntax Analysis or Parsing)

- Έλεγχος αν το πρόγραμμα έχει την **ορθή σύνταξη** σύμφωνα με τις προδιαγραφές της γλώσσας.
 - Ορισμός σύνταξης: Γραμματική!
- Είσοδος: ακολουθία λεκτικών μονάδων από λεκτικό αναλυτή.
- Κατασκευή **συντακτικού δένδρου**
 - Άμεση, όταν τα στάδια μεταγλώττισης είναι διακριτά
 - Έμμεση, στην περίπτωση που δεν αποθηκεύεται σε κάποια μορφή το συντακτικό δένδρο.

Αλληλεπιδράσεις ΛΑ και ΣΑ



Γραμματικές χωρίς συμφραζόμενα

- Γραμματικές τύπου 2
(γραμματικές χωρίς συμφραζόμενα – **context free grammars**)
 - Οι κανόνες παραγωγής έχουν μορφή $\alpha \rightarrow \beta$, όπου η συμβολοσειρά α αποτελείται από **ένα μη-τερματικό σύμβολο** και η β είναι συμβολοσειρά.
- Άρα υπάρχουν κανόνες της μορφής:
 - $A \rightarrow \beta$ όπου $A \in N$. πχ.
 - $\text{smt} \rightarrow \text{if expr then smt}$
 - $\text{smt} \rightarrow \text{while (expr) smts}$

Πρόβλημα Συντακτικής Ανάλυσης

- Πρόβλημα συντακτικής ανάλυσης έγκειται στο να βρεθεί αν μια συμβολοσειρά ανήκει στην γλώσσα που παράγεται από μια γραμματική χωρίς συμφραζόμενα.
- Αλγόριθμοι συντακτικής ανάλυσης:
 - **Καθολικοί (universal)**, οι οποίοι αναγνωρίζουν οποιαδήποτε γραμματική.
 - Από **πάνω προς τα κάτω (top-down parsers)**, όπου γίνεται κατασκευή του δένδρου από την ρίζα προς τα φύλλα.
 - Από **κάτω προς τα πάνω (bottom-up parsers)**, όπου η κατασκευή του δένδρου γίνεται από τα φύλλα προς την ρίζα.

Συντακτικοί Αναλυτές (parsers)

- Οι ΣΑ που χρησιμοποιούνται στην πράξη αφορούν ένα **υποσύνολο** των γραμματικών χωρίς συμφραζόμενα.
 - Επιβολή περιορισμών λόγω αποδοτικότητας.
- Ακόμα και με περιορισμούς εν λόγω γραμματικές καλύπτουν τις ανάγκες των περισσότερων γλωσσών προγραμματισμού.
- Οι από **πάνω προς τα κάτω ΣΑ (top-down parsers)**, ευκολότεροι στην κατασκευή και προγραμματίζονται χειρωνακτικά.
- Οι από **κάτω προς τα πάνω (bottom-up parsers)**, καλύπτουν μια μεγαλύτερη κλάση γλωσσών και κατασκευάζονται συνήθως από αυτοματοποιημένα εργαλεία.

Γλώσσες Προγραμματισμού Μεταγλωττιστές

Στοιχεία Γραμματικών
Χωρίς Συμφραζόμενα
(context free grammars)

Παραγωγές στις Γραμματικές χωρίς Συμφραζόμενα (ΓΧΣ)

- **Παραγωγή:** Αντικατάσταση υποσυμβολοσειράς που ταιριάζει με αριστερό μέλος, με το αντίστοιχο δεξιό μέλος του κανόνα παραγωγής.
- Στις ΓΧΣ κάθε φορά αντικαθίσταται οποιοδήποτε μη-τερματικό σύμβολο που περιέχεται στην συμβολοσειρά.
 - **Αριστερότερη παραγωγή:** αντικατάσταση πάντα του αριστερότερου μη-τερματικού συμβόλου
 - **Δεξιότερη παραγωγή:** αντικατάσταση του δεξιότερου μη-τερματικού συμβόλου.

Παράδειγμα

- Γραμματική

$T = \{+, -, id\}$

$N = \{E, T\}$

$S = \{E\}$

$P = \{$

$E \rightarrow E + T$

$E \rightarrow E - T$

$E \rightarrow T$

$T \rightarrow id\}$

Αριστερότερη παραγωγή:

$E \Rightarrow E + T \Rightarrow T + T \Rightarrow id + T \Rightarrow id + id$

Δεξιότερη παραγωγή:

$E \Rightarrow E + T \Rightarrow E + id \Rightarrow T + id \Rightarrow id + id$

Συντακτικό Δένδρο (syntax tree)

- Τρόπος αναπαράστασης μιας παραγωγής.
- Το αρχικό μη-τερματικό σύμβολο τοποθετείται στη ρίζα του δένδρου.
- Κάθε "ενδιάμεσος" κόμβος του δένδρου αναπαριστά ένα μη-τερματικό σύμβολο.
- Κάθε φύλλο του δένδρου αναπαριστά ένα τερματικό σύμβολο.
- Οι ακμές από ένα "ενδιάμεσο" κόμβο στους απογόνους του αναπαριστούν την αντικατάσταση του μη-τερματικού συμβόλου βάση ενός κανόνα παραγωγής της γραμματικής.


Απλό Παράδειγμα Δένδρου Παραγωγής

$T = \{+, -, id\}$


$N = \{E, T\}$

$S = \{E\}$

$P = \{$
 $E \rightarrow E + T$
 $E \rightarrow E - T$
 $E \rightarrow T$
 $T \rightarrow id\}$



*Από πάνω
προς τα κάτω*




*Από κάτω
προς τα πάνω*

$E \Rightarrow E + T \Rightarrow T + T \Rightarrow id + T \Rightarrow id + id$

Παράδειγμα (II.1)

P={
Stmt → if (Expr) then Stmt
Stmt → while (Expr) Stmt
Stmt → id := id ;
Stmt → id := num ;
Stmt → begin StmtList end
StmtList → Stmt
StmtList → Stmt StmtList
Expr → id Op id
Expr → id Op num
Op → >
Op → <
}

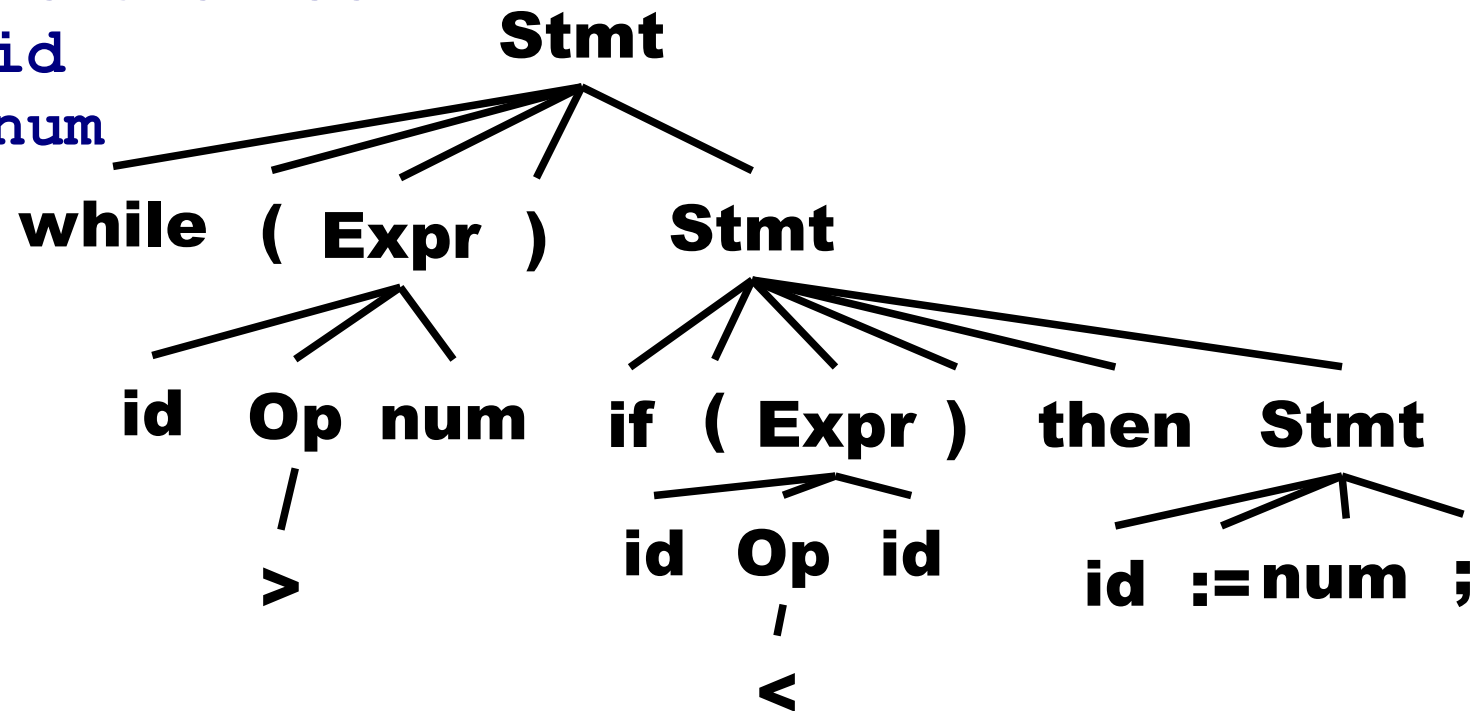


if (id > id) then id := id ;

Παράδειγμα (II.2)

P={
Stmt → if (Expr) then Stmt
Stmt → while (Expr) Stmt
Stmt → id := id ;
Stmt → id := num ;
Stmt → begin StmtList end
StmtList → Stmt
StmtList → Stmt StmtList
Expr → id Op id
Expr → id Op num
Op → >
Op → <
}

while (id > num)
if (id < id) then
id := num;



Αναπαράσταση Γραμματικών

- Καθαρή **Backus-Naur** Μορφή: Απλούστερος, συντομότερος και κομψότερος τρόπος αναπαράστασης γραμματικών.
 - Μη τερματικά σύμβολα οριοθετούνται από γωνιακές παρενθέσεις, "<" και ">"
 - Το σύμβολο \rightarrow αντικαθίσταται από "::=" .
 - Το σύμβολο "|" χρησιμοποιείται για να διαχωρίσει πολλαπλά δεξιά μέλη που αντιστοιχούν σε ένα αριστερό μέλος ενός κανόνα.

$E \rightarrow E + T$

$\langle E \rangle :: = \langle E \rangle + \langle T \rangle \mid \langle E \rangle - \langle T \rangle$

$E \rightarrow E - T$

$T \rightarrow 1$

$\langle T \rangle :: = 1 \mid 2 \mid 3 \dots \mid 0$

$T \rightarrow 2 \dots$

Παραλλαγές Backus Naur Form (BNF)

- Υπάρχουν πολλές παραλλαγές και επεκτάσεις της BNF.
- **Extended BNF (EBNF)**
 - Τερματικά σύμβολα σε εισαγωγικά και μη χρήση γωνιακών παρενθέσεων.
 - Συμβολοσειρές σε αγκύλες "[" και "]" είναι προαιρετικές.
 - Επιτρέπεται χρήση των συμβόλων "*" και "+" με την ίδια σημασία που έχουν και στις κανονικές εκφράσεις.
 - Επιτρέπονται οι παρενθέσεις για ομαδοποίηση συμβόλων.

Παράδειγμα EBNF

Stmt → if (Expr) then Stmt

Stmt → if (Expr) Stmt

Stmt → id := id ;

Stmt → begin StmtList end

StmtList → Stmt

StmtList → Stmt StmtList

Expr → id Op id

Expr → id Op num

Op → >

Op → <

EBNF Μορφή:

Stmt ::= "if" "(" Expr ")" ["then"] Stmt | "id" " := " "id" ";" | "begin" Stmt⁺ "end"

Expr ::= "id" Op "id" | "id" Op "num"

Op ::= ">" | "<"

Αυτόματα Στοιίβας (push-down Automata)

Αυτόματα Στοίβας

- Αφηρημένες Μηχανές οι οποίες λειτουργούν σαν "αναγνωριστές" συμβολοσειρών γραμματικών χωρίς συμφραζόμενα.
- Αποδεικνύεται ότι κάθε ΓΧΣ αντιστοιχεί σε ένα Αυτόματο στοίβας.

Ορισμός Αυτομάτων Στοίβας

- Ένα αυτόματο στοίβας ορίζεται ως $M = \{\Sigma, Q, H, \delta, q_0, h_0, F\}$ όπου
 - Σύνολο συμβόλων εισόδου (αλφάβητο) Σ
 - Πεπερασμένο σύνολο καταστάσεων Q
 - H είναι το αλφάβητο στοίβας
 - Συνάρτηση μετάβασης $\delta: Q \times H \times (\Sigma \cup \{\epsilon\}) \rightarrow P(H^* \times Q)$
 - Αρχική κατάσταση q_0
 - Αρχικό σύμβολο στοίβας h_0
 - Σύνολο τελικών καταστάσεων $F \subseteq Q$

Συνάρτηση μετάβασης δ

- Δύο ειδών μεταβάσεις: **μηδενικές** και **μη-μηδενικές (μεταβάσεις ανάγνωσης)** ανάλογα αν "καταναλώνεται" σύμβολο από την συμβολοσειρά εισόδου.
- Πεδίο τιμών του αυτομάτου είναι ένα σύνολο που περιέχουν κινήσεις. Κάθε κίνηση **(γ, q')** έχει δύο αποτελέσματα:
 - μεταφορά του ΑΣ στην κατάσταση q'
 - τοποθέτηση στην στοίβα της συμβολοσειράς γ ($\gamma \in H^*$) στην στοίβα του αυτομάτου από αριστερά προς τα δεξιά.

Λειτουργία ΑΣ

- Αρχικά το ΑΣ βρίσκεται στην q_0 με αρχικό σύμβολο στοίβας το h_0 .
- Έστω ότι το ΑΣ είναι σε μια κατάσταση q , με h το πρώτο σύμβολο της στοίβας και a το επόμενο σύμβολο εισόδου:
 - αφαιρείται το h από την στοίβα,
 - αν το σύνολο $\delta(q, h, a)$ δεν είναι κενό, επιλέγεται μια κίνηση από αυτό, έστω (γ, q') και το αυτόματο μεταβαίνει στην κατάσταση q' , ενώ τοποθετείται στην στοίβα η γ και καταναλώνεται το a ,
 - αν το σύνολο $\delta(q, h, \varepsilon)$ δεν είναι κενό, επιλέγεται μια κίνηση όπως παραπάνω όμως το a δεν καταναλώνεται.

Λειτουργία ΑΣ

- Το ΑΣ αναγνωρίζει μια συμβολοσειρά εισόδου, όταν μετά το τέλος της εκτέλεσης έχει εξαντληθεί η συμβολοσειρά εισόδου και το ΑΣ βρίσκεται σε μια από τις τελικές καταστάσεις.
 - Μη-ντετερμινισμός: αρκεί μια από τις δυνατές εκτελέσεις να οδηγεί σε τελική κατάσταση.
- **Συνολική κατάσταση (configuration)** είναι η τριάδα **(q, γ, a)** , όπου
 - q είναι η τρέχουσα κατάσταση του ΑΣ,
 - γ η συμβολοσειρά που υπάρχει στη στοίβα και
 - a η μη-αναγνωσμένη συμβολοσειρά εισόδου.

Αναπαράσταση αυτομάτων

- **Πίνακας Μετάβασης:** η πρώτη γραμμή είναι το αλφάβητο της στοίβας (με το σύμβολο \perp) και η πρώτη στήλη οι καταστάσεις του αυτομάτου.
- Μια κίνηση αναπαριστάται (γ, q) από
 - pop, αφαίρεση h από στοίβα
 - push(γ), τοποθέτηση συμβόλων στη στοίβα
 - move(q), μετακίνηση στην κατάσταση q
 - push(ϵ), και move(q) (αν το ΣΑ είναι στην q) παραλείπονται.
 - Το h τοποθετείται εκ νέου στην κορυφή της στοίβας τότε η pop παραλείπεται.
 - read(a) δηλώνει μετάβαση ανάγνωσης, keep μηδενική μετάβαση.

Παράδειγμα

- Αυτόματο το οποίο αναγνωρίζει συμβολοσειρές της μορφής $((()))$ (ισοζυγισμένες παρενθέσεις).
 - $\Sigma = \{ ")", "(", \epsilon \}$
 - $Q = \{S, T\}$
 - $H = \{X, I\}$
 - $\delta(S, X, "(") = \{(XI, S)\}$ $\delta(S, I, "(") = \{(I, S)\}$
 $\delta(S, X, \epsilon) = \{(X, T)\}$ $\delta(S, I, ")") = \{(\epsilon, S)\}$
 - $q_0 = S$
 - $h_0 = X$
 - $F = \{T\}$

Πίνακας Μετάβασης

- $\delta(S, X, "(") = \{(XI, S)\}$
 $\delta(S, I, "(") = \{(II, S)\}$
 $\delta(S, X, \epsilon) = \{(X, T)\}$
 $\delta(S, I, ")") = \{(\epsilon, S)\}$

	X	I	⊥
S	read("(") => push(I) keep => move(T)	read("(") => push(I) read(")") => push(I)	
T			success

Παράδειγμα Εκτέλεσης

- Συμβολοσειρά εισόδου: $((()())$
- Μεταβάσεις:
 $\delta(S, X, "(") = \{(XI, S)\}$
 $\delta(S, I, "(") = \{(II, S)\}$
 $\delta(S, X, \epsilon) = \{(X, T)\}$
 $\delta(S, I, ")") = \{(\epsilon, S)\}$

	Κατάσταση	Στοίβα bottom top	Είσοδος
1	S	X	((()())
2	S	XI	()()
3	S	XII)()
4	S	XI	()
5	S	XII)
6	S	XI)
7	S	X	ϵ
8	T		

Είδη Πεπερασμένων Αυτομάτων

- Ένα ΑΣ ονομάζεται **πραγματικού χρόνου**, όταν δεν περιέχει ε-μετάβασεις και **απλό** όταν έχει μόνο μια κατάσταση.
- Ντετερμινιστικό αυτόματο:
 - Για κάθε $a \in \Sigma \cup \{\epsilon\}, q \in Q, h \in H$ το $\delta(q, h, a)$ έχει το πολύ ένα στοιχείο.
 - Αν υπάρχει $\delta(q, h, \epsilon)$ τότε δεν υπάρχουν μεταβάσεις $\delta(q, h, a)$ για κάθε $a \in \Sigma$.
- Γενικά, δεν υπάρχει ισοδυναμία ανάμεσα σε μη-ντετερμινιστικά και ντετερμινιστικά ΑΣ.

ΑΣ και Μεταγλωττιστές

- Κάθε ΓΧΣ έχει αντίστοιχο ΜΑΣ.
- Ενδιαφέρον (λόγω απόδοσης) έχουν τα ΝΑΣ, άρα ενδιαφέρον για υποσύνολο γλωσσών
 - **Μη-ντετερμινιστικές γλώσσες χωρίς συμφραζόμενα.**
 - Ειδικότερα ενδιαφερόμαστε για γραμματικές LL(1) και LR(1) που αντιστοιχούν σε ΝΑΣ και έχουν εύκολη υλοποίηση.
 - Υποσύνολα των ντετερμινιστικών γλωσσών χωρίς συμφραζόμενα.
- Θα δούμε στη συνέχεια πως "κατασκευάζονται" τέτοια αυτόματα.

Γλώσσες Προγραμματισμού Μεταγλωττιστές

Σχεδιασμός μιας Γραμματικής

Ισοδύναμες Γραμματικές

- Δύο γραμματικές που παράγουν την ίδια γλώσσα ονομάζονται **ισοδύναμες**.
- Συχνά στις γραμματικές γίνονται **μετασχηματισμοί** οι οποίοι δίνουν μια ισοδύναμη γραμματική από μια αρχική περισσότερο πρόσφορη για υλοποίηση.
- Ιδιαίτερα σημαντικό στις **διφορούμενες** γραμματικές.



Διφορούμενες Γραμματικές

- Όταν μια συμβολοσειρά μπορεί να αντιστοιχεί σε δύο συντακτικά δένδρα για μια γραμματική τότε η γραμματική ονομάζεται **διφορούμενη**.
- Για παράδειγμα:

$E ::= E + E \mid E - E \mid E * E \mid E / E \mid D$

$D ::= "1" \mid "2" \mid "3" \mid \dots \mid "9" \mid "0"$

Συμβολοσειρά:
1+2+3



Μετασχηματισμοί

- Διφορούμενες γραμματικές πρέπει να αποφεύγονται κατά την κατασκευή των μεταγλωττιστών.
 - Σημασιολογικές Ασάφειες
- Αρκετές φορές είναι δυνατό να γίνουν κατάλληλοι μετασχηματισμοί οι οποίοι θα οδηγήσουν σε μια **μη-διφορούμενη ισοδύναμη** γραμματική.

Τελεστές και Γραμματικές

- Έκφραση της **προτεραιότητας** και **προσεταιριστικότητας** των τελεστών σε μια γραμματική.
- **Προτεραιότητα τελεστών**: ο τελεστής με την μεγαλύτερη προτεραιότητα παίρνει τα ορίσματα του πριν από τους άλλους τελεστές.
- **Προσεταιριστικότητα**:
 - **Αριστερά προσεταιριστικός** τελεστής: Αριστερά του τελεστή υπάρχει μια υποέκφραση ίδιας προτεραιότητας.
 - **Δεξιά προσεταιριστικός** τελεστής: Δεξιά του τελεστή υπάρχει μια υποέκφραση ίδιας προτεραιότητας.

Τελεστές και Γραμματικές

- Πώς μπορεί να εκφραστεί η προτεραιότητα και προσεταιριστικότητα μέσω μιας μη-διφορούμενης γραμματικής;
 - **Προτεραιότητα:** Για κάθε ομάδα τελεστών ίσης προτεραιότητας, δημιουργούμε ένα μη-τερματικό σύμβολο.
 - **Προσεταιριστικότητα:** Για κάθε τελεστή ορίζεται κατάλληλα ο αντίστοιχος κανόνας παραγωγής.

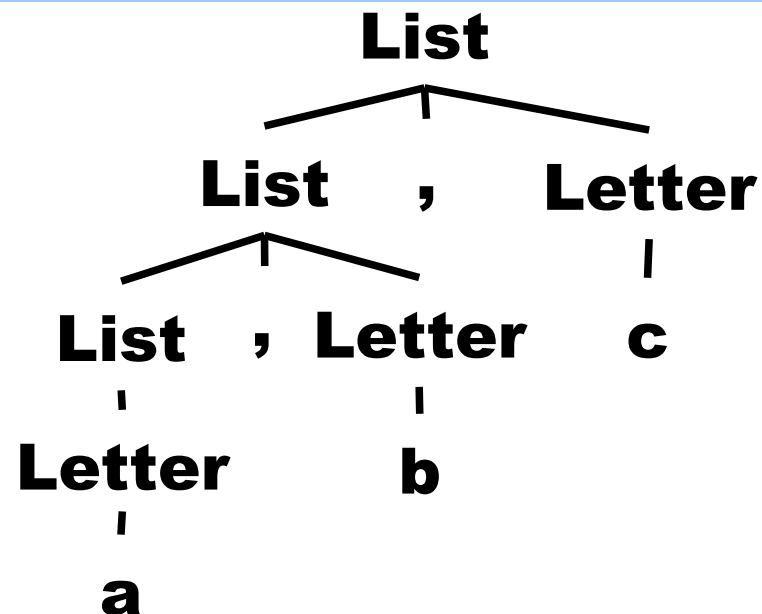
Προσεταιριστικότητα

- Αριστερά προσεταιριστικός τελεστής

$\text{List} ::= \text{List} \, , \, \text{Letter}$

$\text{Letter} ::= "a" | "b" | \dots | "z"$

Συμβολοσειρά a,b,c




- Δεξιά προσεταιριστικός τελεστής

$\text{Assg} ::= \text{Letter} \, = \, \text{Assg} \mid \text{Letter}$

$\text{Letter} ::= "a" | "b" | \dots | "z"$

Συμβολοσειρά a = b = c



Παράδειγμα (i)


- Γραμματική:
 $E ::= E + E \mid E - E \mid E * E \mid E / E \mid D$
 $D ::= "1" \mid "2" \mid "3" \mid \dots \mid "9" \mid "0"$
- Δύο κατηγορίες τελεστών ως προς την προτεραιότητα:
 - αριστερά προσεταιριστικοί "+", "-"
 - δημιουργία μη-τερματικού E
 - αριστερά προσεταιριστικοί "*", "/"
 - δημιουργία μη-τερματικού T.
 - το σύμβολο D παραμένει για να δηλώσει τις βασικές μονάδες.

Παράδειγμα (ii)

- Αρ. προσεταιριστικοί "+", "-" (συμβ. E)
- Αρ. προσεταιριστικοί "*", "/" (συμβ. T)
- το σύμβολο D

- $E ::= E "+" T \mid E "-" T \mid T$
- $T ::= T "*" D \mid T "/" D \mid D$
- $D ::= "1" \mid "2" \mid \dots \mid "9" \mid "0"$

*Συμβολοσειρά 4-3+5*8*



Απαλοιφή Αριστερής Αναδρομής

- **Αριστερά αναδρομικός** κανόνας με:
 - Άμεση αναδρομή $A ::= A\beta$
 - Έμμεση αναδρομή $A ::= a\beta$, όπου σε μία ή περισσότερες παραγωγές η συμβολοσειρά a παράγει την $A\gamma$.
 - Γενικότερα $A \rightarrow a$ και $a \Rightarrow^* A\beta$
- Η αριστερή αναδρομή είναι ανεπιθύμητη στην περίπτωση της **από-πάνω προς τα κάτω** ανάλυσης (top-down).
 - Γιατί;

Μέθοδος Απαλοιφής

- Έστω ο κανόνας

$$A ::= A\alpha_1 | A\alpha_2 | \dots | A\alpha_n | \beta_1 | \dots | \beta_m$$

- Ο μετασχηματισμός περιλαμβάνει την εισαγωγή ενός νέου τερματικού A' και την μεταγραφή του κανόνα στους ακόλουθους:

$$A ::= \beta_1 A' | \dots | \beta_m A'$$

$$A' ::= \alpha_1 A' | \alpha_2 A' | \dots | \alpha_n A' | \varepsilon$$

- Παράδειγμα:

$$\begin{array}{c} E ::= E \text{ "+" } T \mid E \text{ "-" } T \mid T \\ \downarrow \quad \downarrow \quad \downarrow \quad \downarrow \\ A ::= A \alpha_1 \mid A \alpha_2 \mid \beta_1 \end{array}$$

$$A ::= \beta_1 A'$$

γίνεται $E ::= TE'$

$$A' ::= \alpha_1 A' \mid \alpha_2 A' \mid \varepsilon$$

γίνεται $E' ::= \text{"+"} TE' \mid \text{"-"} TE' \mid \varepsilon$

Παράδειγμα Γραμματικής

- Γραμματική με Αριστερή Αναδρομή

$$E ::= E" + "T \mid E" - "T \mid T$$
$$T ::= T" * "D \mid T" / "D \mid D$$
$$D ::= "1" \mid "2" \mid \dots \mid "9" \mid "0"$$

- Ισοδύναμη Γραμματική

$$E ::= TE'$$
$$E' ::= "+"TE' \mid "-"TE' \mid \varepsilon$$
$$T ::= DT'$$
$$T' ::= "*"DT' \mid "/"DT' \mid \varepsilon$$
$$D ::= "1" \mid "2" \mid \dots \mid "9" \mid "0"$$

Αντικατάσταση

- Οι μετασχηματισμοί για τις έμμεσες αναδρομές περιλαμβάνουν **αντικαταστάσεις**, έτσι ώστε οι νέοι κανόνες που θα προκύψουν να είναι άμεσα αναδρομικοί, όπου και εφαρμόζεται η προηγούμενη μέθοδος.
- **Αντικατάσταση** είναι ο μετασχηματισμός στον οποίο αντικαθιστούμε ένα μη-τερματικό σύμβολο B στο δεξιό μέλος ενός κανόνα A με όλα τα εναλλακτικά δεξιά μέλη κανόνων που αφορούν το B .
- $A ::= a_1 B a_2$ $A ::= a_1 \beta_1 a_2 \mid a_1 \beta_2 a_2 \mid \dots \mid a_1 \beta_n a_2$
- $B ::= \beta_1 \mid \beta_2 \mid \dots \mid \beta_n$ $B ::= \beta_1 \mid \beta_2 \mid \dots \mid \beta_n$

Παράδειγμα Έμμεσης Αναδρομής

- Έστω η γραμματική
 $S ::= A \text{ "a" } \mid \text{ "b" }$
 $A ::= A \text{ "c" } \mid S \text{ "d" } \mid \text{ "f" }$
- Κάνοντας τις αντικαταστάσεις
 $S ::= A \text{ "a" } \mid \text{ "b" }$
 $A ::= A \text{ "c" } \mid A \text{ "a" "d" } \mid \text{ "b" "d" } \mid \text{ "f" }$
- Απαλείφοντας την άμεση αριστερή αναδρομή
 $S ::= A \text{ "a" } \mid \text{ "b" }$
 $A ::= \text{ "b" "d" } A' \mid \text{ "f" } A'$
 $A' ::= \text{ "c" } A' \mid \text{ "a" "d" } A' \mid \epsilon$

Αριστερή Παραγοντοποίηση

- Για την αποδοτική υλοποίηση των συντακτικών αναλυτών δεν πρέπει δύο εναλλακτικοί κανόνες για ένα μη-τερματικό να ξεκινούν με το ίδιο πρόθεμα. Δηλαδή:

$$A ::= a\beta_1 | a\beta_2 | \dots | a\beta_n | \gamma_1 | \gamma_2 | \dots | \gamma_n$$



- Η γραμματική με αριστερή παραγοντοποίηση μετατρέπεται στην:

$$A ::= aB | \gamma_1 | \gamma_2 | \dots | \gamma_n$$

$$B ::= \beta_1 | \beta_2 | \dots | \beta_n$$

Το πρόβλημα του μετέωρου else (danfling else)

- Έστω μέρος μιας γραμματικής (other είναι οποιοδήποτε άλλο S)
 $S ::= \text{"if" } E \text{"then" } S \mid \text{"if" } E \text{"then" } S \text{ else } S \mid \text{Other}$
- Ποιό είναι το συντακτικό δένδρο της
 $\text{if } E1 \text{ then if } E2 \text{ then Stm1 else Stm2}$



Μετατροπή σε μη-διφορούμενη γραμματική

- **Βασική ιδέα:** ανάμεσα σε ένα then και σε ένα else δεν πρέπει να υπάρχει ένα "ανοικτό" (unmatched) S. Ως "κλειστό" (matched) S θεωρούμε ένα πλήρες if-then-else ή οποιοδήποτε άλλο S.
 - Το else αντιστοιχεί στο "εσωτερικότερο" if-then.
- Άρα
$$S ::= \text{"if" } E \text{"then" } S \mid \text{"if" } E \text{"then" } S \text{ else } S \mid \text{Other}$$
- Γίνεται:
$$S ::= \text{Mtch} \mid \text{Umtc}$$
$$\text{Mtch} ::= \text{"if" } E \text{"then" } \text{Mtch} \text{ else } \text{Mtch} \mid \text{Other}$$
$$\text{Umtc} ::= \text{"if" } E \text{"then" } S \mid \text{"if" } E \text{"then" } \text{Mtch} \text{ else } \text{Umtc}$$


Το πρόβλημα του μετέωρου else (danfling else)

- Παραγόμενο δένδρο
if E1 then if E2 then Stm1 else Stm2

$S ::= \text{Mtch} \mid \text{Umtc}$

$\text{Mtch} ::= \text{"if" } E \text{ "then" Mtch "else" Mtch} \mid \text{Other}$

$\text{Umtc} ::= \text{"if" } E \text{ "then" } S \mid \text{"if" } E \text{ "then" Mtch "else" Umtc}$



Συναρτήσεις FIRST και FOLLOW

Συναρτήσεις FIRST και FOLLOW

- Οι δύο συναρτήσεις ορίζονται για τα σύμβολα μιας γραμματικής και αφορούν την κατασκευή συντακτικών αναλυτών και των δύο τύπων.
- Έστω μια γραμματική $G = \{T, N, P, S\}$
 - Η συνάρτηση $FIRST(a)$ ορίζεται για κάθε συμβολοσειρά $a \in (T \cup N)^*$ και ισούται με το **σύνολο των τερματικών συμβόλων** με τα οποία μπορεί να **ξεκινά** μια συμβολοσειρά η οποία παράγεται από την a .
 - Η συνάρτηση $FOLLOW(A)$, όπου $A \in N$, είναι το **σύνολο των τερματικών συμβόλων** που μπορεί να **ακολουθούν** την A σε ένα προτασιακό τύπο.

Συνάρτηση FIRST

- Δεδομένης μιας γραμματικής $G = \{T, N, P, S\}$, και $a \in (T \cup N)^*$ (δηλαδή κάθε συμβολοσειρά που αποτελείται από τερματικά και μη-τερματικά σύμβολα της G) η συνάρτηση $\text{FIRST}(a) \subseteq T \cup \{\epsilon\}$, ορίζεται ως:
 - Αν υπάρχει $a \Rightarrow^* \alpha\beta$, όπου α είναι τερματικό σύμβολο, τότε ισχύει $\alpha \in \text{FIRST}(a)$.
 - Αν υπάρχει $a \Rightarrow^* \epsilon$, τότε $\epsilon \in \text{FIRST}(a)$.

Υπολογισμός Συνάρτησης FIRST (i)

- Για κάθε σύμβολο X της γραμματικής G , ισχύουν οι ακόλουθοι κανόνες υπολογισμού:
 - Αν X τερματικό τότε $\text{FIRST}(X) = \{X\}$
 - Αν $X \in N$ και υπάρχει κανόνας $X \rightarrow \varepsilon$, τότε
 $\text{FIRST}(X) = \text{FIRST}(X) \cup \{\varepsilon\}$
 - Αν $X \in N$, και για κάθε κανόνα $X \rightarrow A_1 A_2 \dots A_n$, τότε
 $\text{FIRST}(X) = \text{FIRST}(X) \cup (\text{FIRST}(A_i) - \{\varepsilon\})$, για
κάθε i , τέτοιο ώστε $\forall j \mid 0 < j < i \quad \varepsilon \in \text{FIRST}(A_j)$.
 - Εάν $\forall j \mid 0 < j \leq n \quad \varepsilon \in \text{FIRST}(A_j)$, τότε
 $\text{FIRST}(X) = \text{FIRST}(X) \cup \{\varepsilon\}$
- Οι κανόνες εφαρμόζονται μέχρι να μην μπορούν να μεταβληθούν τα σύνολα FIRST.

Υπολογισμός Συνάρτησης FIRST (ii)

- Για κάθε συμβολοσειρά X_1, X_2, \dots, X_n
 - **$\text{FIRST}(X_1, \dots, X_n) = \text{FIRST}(X_1) - \{\epsilon\}$**
 - Για κάθε $i \mid 1 < i \leq n$, εάν $\forall j \mid 0 < j < i \ \epsilon \in \text{FIRST}(X_j)$ τότε
 $\text{FIRST}(X_1, \dots, X_n) = \text{FIRST}(X_1, \dots, X_n) \cup (\text{FIRST}(X_i) - \{\epsilon\})$
 - Εάν για κάθε $0 < i \leq n$, $\epsilon \in \text{FIRST}(X_i)$, τότε
 $\text{FIRST}(X_1, \dots, X_n) = \text{FIRST}(X_1, \dots, X_n) \cup \{\epsilon\}$

Παράδειγμα Υπολογισμού FIRST

$E \rightarrow TE'$ $\text{FIRST}(E) = \text{FIRST}(T) - \{\epsilon\} = \{\text{id}, (\}$

$E' \rightarrow +TE'$ $\text{FIRST}(E') = \{+, \epsilon\}$

$E' \rightarrow \epsilon$

$T \rightarrow FT'$ $\text{FIRST}(T) = \text{FIRST}(F) - \{\epsilon\} = \{\text{id}, (\}$

$T' \rightarrow *FT'$

$T' \rightarrow \epsilon$ $\text{FIRST}(T') = \{*, \epsilon\}$

$F \rightarrow \text{id}$

$F \rightarrow (E)$ $\text{FIRST}(F) = \text{FIRST}(\text{id}) \cup \text{FIRST}((E)) = \{\text{id}, (\}$

$\text{FIRST}((E)) = \{(\}$

$\text{FIRST}(\text{id}) = \{\text{id}\}$

Συνάρτηση FOLLOW

- Δεδομένης μιας γραμματικής $G = \{T, N, P, S\}$, και $A \in N$, τότε η συνάρτηση $\text{FOLLOW}(A) \subseteq T \cup \{\text{EOF}\}$, ορίζεται ως:
 - Αν υπάρχει παραγωγή $S \Rightarrow^* aAa\beta$, όπου $a, \beta \in (T \cup N)^*$ και a είναι τερματικό σύμβολο, τότε $a \in \text{FOLLOW}(A)$.
 - Αν υπάρχει παραγωγή $S \Rightarrow^* aA$, όπου $a \in (T \cup N)^*$ τότε $\text{EOF} \in \text{FOLLOW}(A)$.

Υπολογισμός της συνάρτησης FOLLOW

- **$\text{FOLLOW}(S) = \{\text{EOF}\}$**
- Για κάθε κανόνα της μορφής $A \rightarrow aB\beta$, όπου A και $B \in N$ και $a, \beta \in (T \cup N)^*$,
 $\text{FOLLOW}(B) = \text{FOLLOW}(B) \cup (\text{FIRST}(\beta) - \{\epsilon\})$
- Εάν $\epsilon \in \text{FIRST}(\beta)$ τότε
 $\text{FOLLOW}(B) = \text{FOLLOW}(B) \cup \text{FOLLOW}(A)$
- Το παραπάνω εκτελείται μέχρι τα σύνολα FOLLOW να μην μεταβάλλονται.

Παράδειγμα Υπολογισμού FOLLOW

$\text{FIRST}(E) = \text{FIRST}(T) = \text{FIRST}(F) = \{\text{id},)\}$

$\text{FIRST}(E') = \{+, \epsilon\}$ $\text{FIRST}(T') = \{*, \epsilon\}$

$E \rightarrow TE'$

$E' \rightarrow +TE'$

$E' \rightarrow \epsilon$

$T \rightarrow FT'$

$T' \rightarrow *FT'$

$T' \rightarrow \epsilon$

$F \rightarrow \text{id}$

$F \rightarrow (E)$

$\text{FOLLOW}(E) = \{\text{EOF}\}$ (αρχικό σύμβολο)

▪ Υπολογισμός $\text{FOLLOW}(E)$

$F \rightarrow (E)$

$\text{FOLLOW}(E) = \text{FOLLOW}(E) \cup (\text{FIRST}() - \{\epsilon\}) = \{\text{EOF},)\}$

▪ Υπολογισμός $\text{FOLLOW}(E')$

$E \rightarrow TE'$

$\text{FOLLOW}(E') = \text{FOLLOW}(E') \cup (\text{FIRST}(\epsilon) - \{\epsilon\}) = \{\}$

$\text{FOLLOW}(E') = \text{FOLLOW}(E') \cup \text{FOLLOW}(E) = \{\text{EOF},)\}$

$E' \rightarrow +TE'$

$\text{FOLLOW}(E') = \text{FOLLOW}(E') \cup (\text{FIRST}(\epsilon) - \{\epsilon\}) = \{\text{EOF},)\}$

$\text{FOLLOW}(E') = \text{FOLLOW}(E') \cup \text{FOLLOW}(E') = \{\text{EOF},)\}$

Παράδειγμα Υπολογισμού FOLLOW

$\text{FIRST}(E) = \text{FIRST}(T) = \text{FIRST}(F) = \{\text{id}, \text{,}\}$

$\text{FIRST}(E') = \{+, \varepsilon\}$ $\text{FIRST}(T') = \{*, \varepsilon\}$

$E \rightarrow TE'$

$E' \rightarrow +TE'$

$E' \rightarrow \varepsilon$

$T \rightarrow FT'$

$T' \rightarrow *FT'$

$T' \rightarrow \varepsilon$

$F \rightarrow \text{id}$

$F \rightarrow (E)$

▪ Υπολογισμός FOLLOW(T)

$E \rightarrow TE'$

$\text{FOLLOW}(T) = \text{FOLLOW}(T) \cup (\text{FIRST}(E') - \{\varepsilon\}) = \{+\}$

$\text{FOLLOW}(T) = \text{FOLLOW}(T) \cup \text{FOLLOW}(E') = \{\text{EOF}, \text{,}, +\}$

$E' \rightarrow +TE'$

$\text{FOLLOW}(T) = \text{FOLLOW}(T) \cup (\text{FIRST}(\varepsilon) - \{\varepsilon\}) = \{\}$

$\text{FOLLOW}(T) = \text{FOLLOW}(T) \cup \text{FOLLOW}(E') = \{\text{EOF}, \text{,}, +\}$

Παράδειγμα Υπολογισμού FOLLOW

$\text{FIRST}(E) = \text{FIRST}(T) = \text{FIRST}(F) = \{\text{id}, \text{,}\}$

$\text{FIRST}(E') = \{+, \varepsilon\}$ $\text{FIRST}(T') = \{*, \varepsilon\}$

$E \rightarrow TE'$

$E' \rightarrow +TE'$

$E' \rightarrow \varepsilon$

$T \rightarrow FT'$

$T' \rightarrow *FT'$

$T' \rightarrow \varepsilon$

$F \rightarrow \text{id}$

$F \rightarrow (E)$

▪ Υπολογισμός FOLLOW(T')

$T \rightarrow FT'$

$\text{FOLLOW}(T') = \text{FOLLOW}(T') \cup (\text{FIRST}(\varepsilon) - \{\varepsilon\}) = \{\}$

$\text{FOLLOW}(T') = \text{FOLLOW}(T') \cup \text{FOLLOW}(T) = \{\text{EOF}, \text{,}, +\}$

$T' \rightarrow *FT'$

$\text{FOLLOW}(T') = \text{FOLLOW}(T') \cup (\text{FIRST}(\varepsilon) - \{\varepsilon\}) = \{\text{EOF}, \text{,}, +\}$

$\text{FOLLOW}(T') = \text{FOLLOW}(T') \cup \text{FOLLOW}(T') = \{\text{EOF}, \text{,}, +\}$

Παράδειγμα Υπολογισμού FOLLOW

$\text{FIRST}(E) = \text{FIRST}(T) = \text{FIRST}(F) = \{\text{id}, \text{,}\}$

$\text{FIRST}(E') = \{+, \varepsilon\}$ $\text{FIRST}(T') = \{*, \varepsilon\}$

$E \rightarrow TE'$

$E' \rightarrow +TE'$

$E' \rightarrow \varepsilon$

$T \rightarrow FT'$

$T' \rightarrow *FT'$

$T' \rightarrow \varepsilon$

$F \rightarrow \text{id}$

$F \rightarrow (E)$

▪ Υπολογισμός FOLLOW(F)

$T \rightarrow FT'$

$\text{FOLLOW}(F) = \text{FOLLOW}(F) \cup (\text{FIRST}(T') - \{\varepsilon\}) = \{*\}$

$\text{FOLLOW}(F) = \text{FOLLOW}(F) \cup \text{FOLLOW}(T) = \{\text{EOF}, \text{,}, +, *\}$

$T' \rightarrow *FT'$

$\text{FOLLOW}(F) = \text{FOLLOW}(F) \cup (\text{FIRST}(T') - \{\varepsilon\}) = \{\text{EOF}, \text{,}, +, *\}$

$\text{FOLLOW}(F) = \text{FOLLOW}(F) \cup \text{FOLLOW}(T') = \{\text{EOF}, \text{,}, +, *\}$

Παράδειγμα Υπολογισμού FIRST & FOLLOW

$E \rightarrow TE'$

$E' \rightarrow +T$

$E' \rightarrow \varepsilon$

$T \rightarrow FT'$

$T' \rightarrow *F$

$T' \rightarrow \varepsilon$

$F \rightarrow \text{id}$

$F \rightarrow (E)$

- $\text{FIRST}(E) = \text{FIRST}(T) = \text{FIRST}(F) = \{\text{id}, (\}$
- $\text{FIRST}(E') = \{+, \varepsilon\}$
- $\text{FIRST}(T') = \{*, \varepsilon\}$

- $\text{FOLLOW}(E) = \{\text{EOF},)\}$
- $\text{FOLLOW}(E') = \{\text{EOF},)\}$
- $\text{FOLLOW}(T) = \{\text{EOF},), +\}$
- $\text{FOLLOW}(T') = \{\text{EOF},), +\}$
- $\text{FOLLOW}(F) = \{\text{EOF},), +, *\}$

Συντακτική Ανάλυση
από Πάνω προς τα Κάτω
(top-down)


Συντακτική Ανάλυση από Πάνω προς τα Κάτω

- Η συντακτική ανάλυση ξεκινά από το αρχικό σύμβολο της γραμματικής (ρίζα του συντακτικού δένδρου) και αντικαθιστά αυτό με τα σύμβολα από ένα κανόνα παραγωγής. Η διαδικασία συνεχίζεται με τους επόμενους κόμβους μέχρι όλα τα φύλλα του δένδρου να είναι τερματικά σύμβολα της γραμματικής.
 - **Με ποια σειρά θα εξεταστούν οι κόμβοι παιδιά ενός κόμβου;**
 - **Ποιος από τους πιθανούς εναλλακτικούς κανόνες θα χρησιμοποιηθεί για την αντικατάσταση του μη-τερματικού συμβόλου;**

- Με ποια σειρά θα εξεταστούν οι κόμβοι παιδιά ενός κόμβου;

- Οι πλειοψηφία των συντακτικών αναλυτών επεκτείνουν τους νέους κόμβους από τα αριστερά προς τα δεξιά (**Left-to-right**) σύμφωνα με την σειρά εμφάνισης τους στο δεξιό μέλος του αντίστοιχου κανόνα παραγωγής.

- $A ::= "a" B "a" \Gamma$
- $B ::= "b"$
- $\Gamma ::= "c"$



Ποιος από τους πιθανούς εναλλακτικούς κανόνες θα χρησιμοποιηθεί για την αντικατάσταση του μη-τερματικού συμβόλου;

- Επιλογή κατάλληλου κανόνα είναι ένα δύσκολο ζήτημα (για να λυθεί αποδοτικά).
 - Η περίπτωση της οπισθοδρόμησης δεν είναι αποδεκτή.
- Συνήθως ο ΣΑ διαβάζει ένα ή περισσότερα σύμβολα ώστε να αποφασίσει ποιος είναι ο κατάλληλος κανόνας (look-ahead symbols).
 - **LL(k)**: ΣΑ που διαβάζει την συμβολοσειρά από αριστερά προς τα δεξιά (Left-to-right), κατασκευάζει την αριστερότερη παραγωγή (Leftmost derivation) και απαιτεί k σύμβολα εισόδου.
 - π.χ. LL(1) ΣΑ

LL(1) Γραμματικές

- **LL(1) γραμματική:** Αναγνώσιμη από ένα LL(1) ΣΑ (αναδρομικής κατάβασης ή ΑΣ).
 - Υποσύνολο των γραμματικών χωρίς συμφραζόμενα, αρκετά πλούσιο όμως για να περιγράψει τις περισσότερες γλώσσες.
- Προϋποθέσεις:
 - Για κάθε ζεύγος κανόνων παραγωγής $A \rightarrow \alpha$ και $A \rightarrow \beta$ πρέπει να ισχύει $\mathbf{FIRST(\alpha) \cap FIRST(\beta) = \emptyset}$.
 - Αν το ϵ ανήκει στο $\mathbf{FIRST(A)}$ (για παράδειγμα υπάρχει κανόνας $A \rightarrow \epsilon$) πρέπει να ισχύει $\mathbf{FIRST(A) \cap FOLLOW(A) = \emptyset}$.

LL(1) Γραμματικές

- Αποκλείονται οι γραμματικές:
 - Αριστερά αναδρομικές
 - Έχουν δύο εναλλακτικούς κανόνες με δεξιά μέλη που ξεκινούν με το ίδιο σύμβολο.
 - Έχουν δύο εναλλακτικούς κανόνες τα δεξιά μέλη των οποίων παράγουν την κενή συμβολοσειρά.
- Πως επιτυγχάνεται το παραπάνω;
 - Απαλοιφή αριστερής αναδρομής
 - Αντικατάσταση
 - Αριστερή παραγοντοποίηση

ΣΑ Αναδρομικής Κατάβασης

- Recursive Descent
- ΣΑ από πάνω προς τα κάτω, εύκολα κατασκευάσιμος χειρωνακτικά.
- Σε κάθε μη-τερματικό σύμβολο, αντιστοιχίζεται μια ρουτίνα η οποία το αναγνωρίζει.
- **Αποφυγή οπισθοδρόμησης:** Χρήση της συνάρτησης FIRST για την επιλογή της κατάλληλης ρουτίνας για την αναγνώριση, εξετάζοντας την επόμενη λεκτική μονάδα (lookahead).

ΣΑ Αναδρομικής Κατάβασης (ii)

- Έστω $A ::= a_1 | a_2 | \dots | a_n$ και η επόμενη λεκτική μονάδα είναι η token.
- Ο κώδικας για την αναγνώριση της A είναι:
 if token \in FIRST(a_1) **then** <κώδικας για την a_1 >
 ...
 ifelse token \in FIRST(a_n) **then** <κώδικας για την a_n >
 ifelse $\varepsilon \notin$ FIRST(a_1) $\cup \dots \cup$ FIRST(a_n) **then**
 <συντακτικό σφάλμα>
 ifelse token \notin FOLLOW(A) **then**
 <συντακτικό σφάλμα>

ΣΑ Αναδρομικής Κατάβασης (iii)

- Κώδικας για το δεξιό μέλος των κανόνων
 - Η κενή συμβολοσειρά δεν απαιτεί κώδικα
 - Ένα τερματικό t αναγνωρίζεται από τον κώδικα
match(a):
match(t : token)
 if lookahead = t **then** lookahead := nexttoken()
 else syntax_error
 - Ένα μη-τερματικό σύμβολο A αναγνωρίζεται από την κλήση στη ρουτίνα που αναγνωρίζει το A .
 - Παράθεση δύο συμβολοσειρών $\alpha\beta$ αναγνωρίζεται καλώντας τον τον κώδικα για την α και τον κώδικα για την β .

Παράδειγμα Γραμματικής

$E \rightarrow TE'$

$E' \rightarrow +TE'$

$E' \rightarrow \varepsilon$

$T \rightarrow FT'$

$T' \rightarrow *FT'$

$T' \rightarrow \varepsilon$

$F \rightarrow \text{id}$

$F \rightarrow (E)$

- $\text{FIRST}(E) = \text{FIRST}(T) = \text{FIRST}(F) = \{\text{id}, (\}$
- $\text{FIRST}(E') = \{+, \varepsilon\}$
- $\text{FIRST}(T') = \{*, \varepsilon\}$

- $\text{FOLLOW}(E) = \{\text{EOF},)\}$
- $\text{FOLLOW}(E') = \{\text{EOF},)\}$
- $\text{FOLLOW}(T) = \{\text{EOF},), +\}$
- $\text{FOLLOW}(T') = \{\text{EOF},), +\}$
- $\text{FOLLOW}(F) = \{\text{EOF},), +, *\}$

Παράδειγμα Γραμματικής

$E \rightarrow TE'$
 $E' \rightarrow +TE'$
 $E' \rightarrow \varepsilon$
 $T \rightarrow FT'$
 $T' \rightarrow *FT'$
 $T' \rightarrow \varepsilon$
 $F \rightarrow id$
 $F \rightarrow (E)$

▪ **FIRST(TE') = {id,(}**

void **E()**

if token = id or token = (
 call T() call E'()

else syntax_error

▪ **FIRST(+T) = {+}** **FOLLOW(E')={EOF,)}**

void **E'()**

if token = + then

 match(+) call T() call E'()

elseif token **not_in** { EOF,) } then syntax_error

Παράδειγμα Γραμματικής

$E \rightarrow TE'$
 $E' \rightarrow +TE'$
 $E' \rightarrow \varepsilon$
 $T \rightarrow FT'$
 $T' \rightarrow *FT'$
 $T' \rightarrow \varepsilon$
 $F \rightarrow id$
 $F \rightarrow (E)$

▪ **FIRST(FT') = {id,(}**

void **T()**

if token = id or token = (
 call F() call T'()

else syntax_error

▪ **FIRST(*F) = {*}** **FOLLOW(T')={EOF,),+}**

void **T'()**

if token = * then

 match(*) call F() call T'()

elseif token **not_in** { EOF,),+} then syntax_error

Παράδειγμα Γραμματικής

$E \rightarrow TE'$
 $E' \rightarrow +TE'$
 $E' \rightarrow \varepsilon$
 $T \rightarrow FT'$
 $T' \rightarrow *FT'$
 $T' \rightarrow \varepsilon$
 $F \rightarrow id$
 $F \rightarrow (E)$

▪ **FIRST(id) = {id}** **FIRST((E)) = {(}**

void **F()**

if token = id then match(id)

elseif token = (then

match(() call E() match())

else syntax_error

void **syntaxAnalysis()**

token = nexttoken()

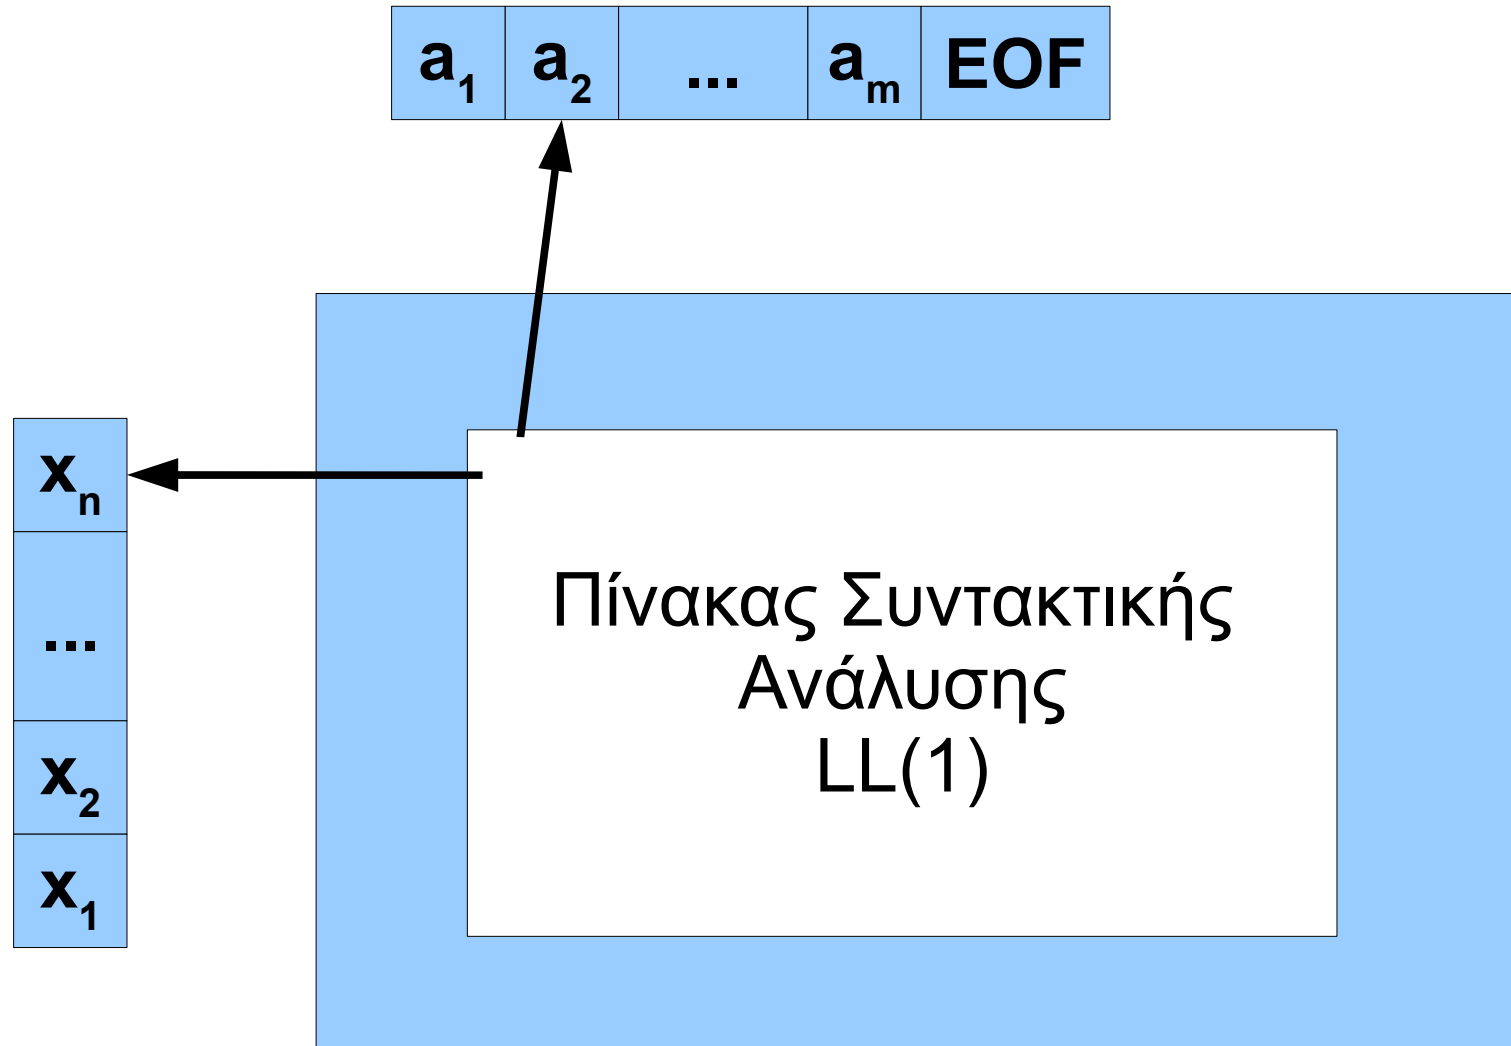
call E()

if token != EOF then syntax_error

Μη-αναδρομικοί συντακτικοί αναλυτές LL(1)

- Είναι δυνατό να κατασκευαστεί ένα ειδικό αυτόματο στοίβας για μια LL(1) γραμματικοί.
- Συνήθως τέτοιοι ΣΑ κατασκευάζονται με αυτόματο τρόπο.
- Το αυτόματο αποτελείται από:
 - **ενδιάμεση μνήμη**, από όπου διαβάζεται η συμβολοσειρά εισόδου,
 - **στοίβα**, όπου τοποθετούνται τα τερματικά και μη-τερματικά σύμβολα της γραμματικής.
 - **πίνακας συντακτικής ανάλυσης**, με μια γραμμή για κάθε μη-τερματικό σύμβολο και μια στήλη για κάθε τερματικό σύμβολο της γραμματικής και το σύμβολο EOF.

ΣΑ LL(1) Αυτομάτου Στοίβας



Κατασκευή Πίνακα Συντακτικής Ανάλυσης

- Για κάθε κανόνα παραγωγής $A \rightarrow \beta$:
 - Για κάθε τερματικό σύμβολο $a \mid a \in \text{FIRST}(\beta)$, πρόσθεσε τον κανόνα $A \rightarrow \beta$ στη θέση $M[A, a]$
 - Αν $\epsilon \in \text{FIRST}(\beta)$, τότε για κάθε τερματικό σύμβολο $a \in \text{FOLLOW}(A)$, πρόσθεσε τον κανόνα $A \rightarrow \beta$ στην θέση $M[A, a]$.
 - Αν $\epsilon \in \text{FIRST}(\beta)$ και $\text{EOF} \in \text{FOLLOW}(A)$ τότε πρόσθεσε τον κανόνα $A \rightarrow \beta$ στην θέση $M[A, \text{EOF}]$
 - Όσες θέσεις του πίνακα μένουν κενές συμπληρώνονται με την ένδειξη error (ή απλώς υπονοείται).

Παράδειγμα Κατασκευής Πίνακα Συντακτικής Ανάλυσης

$E \rightarrow TE'$

$E' \rightarrow +TE'$

$E' \rightarrow \varepsilon$

$T \rightarrow FT'$

$T' \rightarrow *FT'$

$T' \rightarrow \varepsilon$

$F \rightarrow \text{id}$

$F \rightarrow (E)$

- $\text{FIRST}(E) = \text{FIRST}(T) = \text{FIRST}(F) = \{\text{id}, (\}$
- $\text{FIRST}(E') = \{+, \varepsilon\}$
- $\text{FIRST}(T') = \{*, \varepsilon\}$
- $\text{FOLLOW}(E) = \{\text{EOF},)\}$
- $\text{FOLLOW}(E') = \{\text{EOF},)\}$
- $\text{FOLLOW}(T) = \{\text{EOF},), +\}$
- $\text{FOLLOW}(T') = \{\text{EOF},), +\}$
- $\text{FOLLOW}(F) = \{\text{EOF},), +, *\}$

	id	+	*	()	EOF
E	$E \rightarrow TE'$			$E \rightarrow TE'$		
E'		$E' \rightarrow +TE'$			$E' \rightarrow \varepsilon$	$E' \rightarrow \varepsilon$

Παράδειγμα Κατασκευής Πίνακα Συντακτικής Ανάλυσης

- Ο πλήρης πίνακας για την συγκεκριμένη γραμματική είναι:

	id	+	*	()	EOF
E	$E \rightarrow TE'$			$E \rightarrow TE'$		
E'		$E' \rightarrow +TE'$			$E' \rightarrow \varepsilon$	$E' \rightarrow \varepsilon$
T	$T \rightarrow FT'$			$T \rightarrow FT'$		
T'		$T' \rightarrow \varepsilon$	$T' \rightarrow *FT'$		$T' \rightarrow \varepsilon$	$T' \rightarrow \varepsilon$
F	$F \rightarrow \text{id}$			$F \rightarrow (E)$		

Λειτουργία ΣΑ LL(1)

- Συμπίπτει με την λειτουργία του ΑΣ.
- Μέχρι η στοίβα να είναι κενή:
 - Αν στην κορυφή της στοίβας βρίσκεται το **τερματικό σύμβολο a** το οποίο συμπίπτει με το επόμενο σύμβολο της συμβολοσειράς εισόδου, τότε το a αφαιρείται από τη στοίβα και το αυτόματο προχωρά στο επόμενο σύμβολο.
 - Αν στην κορυφή της στοίβας είναι το **μη-τερματικό A** , και το επόμενο σύμβολο της συμβολοσειράς εισόδου τότε είναι το a , και υπάρχει κανόνας **$A \rightarrow \beta$** στο **$M[A, a]$** , τότε το A αφαιρείται από τη στοίβα και τοποθετούνται τα σύμβολα του β στη στοίβα.
 - Αλλιώς σφάλμα.

Παράδειγμα: Συμβολοσειρά $id+id*id$

	Στοίβα	Είσοδος	Κανόνας/Κίνηση
0	E	$id + id * id$ EOF	$E \rightarrow T E'$
1	$E' T$	$id + id * id$ EOF	$T \rightarrow F T'$
2	$E' T' F$	$id + id * id$ EOF	$F \rightarrow id$
3	$E' T' id$	$id + id * id$ EOF	pop(id)
4	$E' T'$	$+ id * id$ EOF	$T' \rightarrow \varepsilon$
5	E'	$+ id * id$ EOF	$E' \rightarrow + T E'$
6	$E' T +$	$+ id * id$ EOF	pop(+)
7	$E' T$	$id * id$ EOF	$T \rightarrow F T'$
8	$E' T' F$	$id * id$ EOF	$F \rightarrow id$
9	$E' T' id$	$id * id$ EOF	pop(id)
10	$E' T'$	$* id$ EOF	$T' \rightarrow * F T'$
11	$E' T' F *$	$* id$ EOF	pop(*)
12	$E' T' F$	id EOF	$F \rightarrow id$
13	$E' T' id$	id EOF	pop(id)
14	$E' T'$	EOF	$T' \rightarrow \varepsilon$
15	E'	EOF	$E' \rightarrow \varepsilon$
16	ε	EOF	success

Ανάνηψη από Σφάλματα

- Η βασική ιδέα είναι να γίνει η ανίχνευση ενός σφάλματος και να:
 - γίνει η έξοδος μηνύματος λάθους με σαφήνεια και ακρίβεια
 - προχωρήσει η μεταγλωττιστής στην επεξεργασία της υπόλοιπης συμβολοσειράς εισόδου, ώστε να εντοπιστούν τυχόν άλλα σφάλματα.
 - μην καθυστερεί πολύ η μεταγλώττιση του προγράμματος.

Μέθοδος Πανικού

- Απλούστερη στρατηγική ανάνηψης από σφάλματα (panic mode).
- Ανάγνωση επόμενων λεκτικών μονάδων από την είσοδο, μέχρι να βρεθεί λεκτική μονάδα η οποία να ανήκει στο **σύνολο "συγχρονισμού"**.
 - Κατάλληλες λεκτικές μονάδες και διαχωριστές.
- Επιλογή των κατάλληλων λεκτικών μονάδων στο σύνολο εξαρτάται από την γλώσσα.
- Παραλείπει κάποια σφάλματα
 - Παραδοχή ότι τα δεν εμφανίζονται συχνά περισσότερα του ενός σφάλματα σε μια γραμμή.

Ανάνηψη από σφάλματα σε LL(1) ΣΑ

- Σφάλμα διαπιστώνεται όταν:
- Αν το **τερματικό σύμβολο** στην κορυφή της στοίβας δεν είναι ίδιο με το επόμενο τερματικό σύμβολο εισόδου.
- Αν για το **μη-τερματικό σύμβολο** της στοίβας και το επόμενο τερματικό σύμβολο της εισόδου, δεν υπάρχει κανόνας στον πίνακα συντακτικής ανάλυσης.

Μέθοδος Πανικού σε LL(1) ΣΑ (i)

- Καθορισμός του συνόλου χρονισμού:
 - Τα σύμβολα στο σύνολο **FOLLOW(A)**. Αφαιρούμε από την είσοδο λεκτικές μονάδες μέχρι να φτάσουμε σε μια η οποία ανήκει στο FOLLOW(A), και αφαιρούμε το A από την στοίβα.
 - Δεν είναι πάντα η κατάλληλη μέθοδος, καθώς αν λείπει ένας διαχωριστικός χαρακτήρας (πχ ";" στη C) οι λεκτικές μονάδες με τις οποίες ξεκινούν οι επόμενες εκφράσεις δεν θα είναι στο FOLLOW(A). Προσθήκη στο σύνολο χρονισμού των "χαμηλότερων" στην ιεραρχία μη-τερματικών, συνόλων FIRST "υψηλότερων" μη-τερματικών.

Μέθοδος Πανικού σε LL(1) ΣΑ (ii)

- Μπορούν να προστεθούν σύμβολα από το $FIRST(A)$ στο και αν βρεθεί κάποιο από αυτά στη συμβολοσειρά εισόδου να συνεχιστεί η αναγνώριση του A .
- Εάν ένα μη-τερματικό παράγει την κενή συμβολοσειρά, τότε αυτή η παραγωγή προτιμάται.
- Αν ένα τερματικό είναι στην κορυφή της στοίβας τότε απλώς αφαιρείται από αυτή και δίνεται το κατάλληλο μήνυμα λάθους.

Ανάνηψη σε επίπεδο Φάσης (phase-level recovery)

- Σύμφωνα με την στρατηγική, σε κάθε κενή θέση του πίνακα συντακτικής ανάλυσης, αντιστοιχίζεται μια ρουτίνα σφάλματος, η οποία:
 - τυπώνει το κατάλληλο διαγνωστικό μήνυμα
 - Εισάγει/διαγράφει ή μεταβάλλει το σύμβολο εισόδου
 - Αφαιρεί το τρέχον σύμβολο από την στοίβα.
- Κίνδυνος ατερμόνων βρόχων
 - πχ. στην εισαγωγή ενός συμβόλου
- Η εισαγωγή ενός συμβόλου μπορεί να οδηγήσει σε μη επιτρεπτή συμβολοσειρά εισόδου.

Σύνοψη

- Συντακτική Ανάλυση
- Γραμματικές χωρίς συμφραζόμενα.
 - Αυτόματα Στοίβας
- Οι συναρτήσεις FIRST και FOLLOW.
- Συντακτικοί Αναλυτές από πάνω προς τα κάτω (top-down)